

Εργασία Ανάκτησης Πληροφορίας

Μαρία Νεφέλη Τυχάλα, 4152, mtychala@csd.auth.gr

Άγγελος Μανουσέλης, 3520, manousela@csd.auth.gr

Η εργασία αυτή στοχεύει στην εφαρμογή τεχνικών Ανάκτησης Πληροφορίας στις ομιλίες της Βουλής των Ελλήνων χρησιμοποιούνται τεχνικές εξαγωγής λέξεων-κλειδιών, υπολογισμού ομοιότητας μεταξύ βουλευτών και Latent Semantic Indexing για θεματική ανάλυση.

Τεχνολογίες που χρησιμοποιήσαμε

Η εφαρμογή υλοποιήθηκε σε Python 3.13.9 (σε 3.14 δεν λειτουργεί), με τοπικό server Flask και front-end βασισμένο σε Jinja και Bootstrap. Οι ομιλίες αποθηκεύονται σε βάση δεδομένων SQLite και για την επεξεργασία κειμένου χρησιμοποιούνται το εργαλείο `greek_stemmer_plus` για stemming. Το LSI γίνεται μέσω SVD του `scikit-learn`.

Επεξεργασία κειμένου

Για αρχή γίνεται ένας καθαρισμός του κειμένου με regular expressions και μετά stemming με την χρήση της βιβλιοθήκης `greek_stemmer_plus`. Σε αυτήν την διαδικασία φτιάχνεται και ένα map με τα stems και κάποια ενδεικτική λέξη ώστε να είναι πιο κατανοητά τα αποτελέσματα. Η υλοποίηση γίνεται στο αρχείο `text_processor.py`.

TF-IDF

Το term frequency υπολογίζεται με

$$tf(t, d) = 1 + \log(f_{td})$$

Το inverse document frequency υπολογίζεται με

$$idf(t) = \log\left(\frac{N+1}{df(t)}\right)$$

Και τα βάρη με

$$w_{td} = tf(t, d) * idf(t)$$

Οι τύποι είναι ίδιοι και για το query. Για την αναζήτηση βρίσκουμε τις μεγαλύτερες τιμές από την πράξη.

$$w * q$$

δεν γίνεται κανονικοποίηση γιατί παρατηρήσαμε καλύτερα αποτελέσματα στο απλό dot product από το cosine similarity.

Τα βάρη αποθηκεύονται σε έναν αραιό πίνακα της βιβλιοθήκης `scipy`. Η υλοποίηση βρίσκεται στο αρχείο `tfidf.py`

Keywords

Για την εξαγωγή των keywords βρίσκουμε τις λέξεις με τα μεγαλύτερα βάρη σε κάθε ομιλία (ανά βουλευτή ή κόμμα). Η υλοποίηση βρίσκεται στο αρχείο `keywords.py`

LSI

Για να εντοπιστούν θεματικές περιοχές χρησιμοποιήθηκε SVD από το `scikit-learn`, κάθε ομιλία εκφράζεται ως διάνυσμα σε πολυδιάστατο χώρο και στην συνέχεια υπολογίζεται μια ‘μέση ομιλία’ για κάθε βουλευτή που λειτουργεί σαν ένα διάνυσμα χαρακτηριστικών. Στην συνέχεια γίνεται σύγκριση ανά ζεύγη. Η υλοποίηση βρίσκεται στο αρχείο `lsi.py`

Οδηγίες

Για να τρέξετε την εφαρμογή βεβαιωθείτε ότι έχετε εγκατεστημένες τις βιβλιοθήκες που χρειάζεται, υπάρχει αρχείο `requirements.txt`, άρα μπορείτε να εγκαταστήσετε με

```
pip install -r requirements.txt
```

Επίσης βεβαιωθείτε ότι το αρχείο του dataset με όνομα `Greek_Parliament_Proceedings_1989_2020.csv` βρίσκεται στον φάκελο του project. Μετά από αυτά τα βήματα μπορείτε να τρέξετε το αρχείο `app.py` και θα ανοίξει αυτόματα καρτέλα στον browser σας. Αν δεν ανοίξει για κάποιον λόγο θα βρείτε την εφαρμογή στο `localhost:5000/`.

Η πρώτη φορά που θα τρέξει η εφαρμογή μπορεί να αργήσει λόγο των υπολογισμών, αλλά γίνεται caching ώστε να τρέχει γρήγορα μετά την πρώτη εκκίνηση.